

Анализ зашумленных и частично наблюдаемых данных судовых навигационных систем

Гашков С.П.

Глава 1

Замеры параметров модели

Для проведения анализа были получены данные о треках 3 судов в разных областях страны, разной конструкции и назначения. Данные представляют собой записи показаний датчика GPS за период 01.05.2026 – 01.08.2026.

Данные оформлены в виде csv файлов (https://drive.google.com/drive/folders/1QRGCgJsDWzg9diWw_WM7iAPTSN8s3np?usp=sharing) следующей структуры:

1. time - время записи
2. lat - долгота
3. lon - широта
4. sat - количество спутников
5. status - разметка точки(anomaly, stand или move)
6. is_water - находится ли точка на воде

Поле is_water получено как проверка соответствующей координаты с помощью открытой векторной базы данных картографии OpenStreetMap: если по координатам точки есть хотя бы один объект, помеченный тегом water - поле принимает значение true, иначе false.

Поле status добавлено в ходе разметки трека и является информацией о том, какова природа этой точки. Anomaly - точка является аномальной

(полученной в результате сбоя GPS), точки данного класса и необходимо обнаруживать. Stand - точка, в которой судно стояло на месте; отличие двух последовательных координат, имеющих такой класс обусловлено естественным дрейфом судна (в т.ч. на якоре) или дрейфом самого gps. Move - точка, в которой судно двигалось.

Основной целью работы является выделение точек класса anomaly. Другие классы приведены в справочном формате.

1.1 Замер 1

Перед выполнение эксперимента проведена предварительная фильтрация точек. Из наборов были удалены точки, чей sat (количество видимых спутников) меньше 3 или is_water являются False.

1.1.1 Цель эксперимента

Целью эксперимента являлась оценка возможности применения фильтра Калмана для обнаружения аномальных GPS-наблюдений посредством анализа инноваций и их нормированной квадратичной формы. Исследование проводилось для двух моделей движения: модели постоянной скорости (Constant Velocity, CV) и модели случайного блуждания (Random Walk, RW).

В качестве основных параметров моделей рассматривались среднеквадратическое отклонение ошибки измерения положения σ_{meas} , а также параметр дисперсии процесса: σ_{acc} для CV и σ_{rw} для RW. Параметры оценивались методом максимального правдоподобия (Maximum Likelihood Estimation, MLE). Реализованный алгоритм выполняет обработку непрерывных участков треков и формирует локальные окна длиной $W = 10$ наблюдений. Для каждого окна локальная система координат задаётся относительно первой точки окна. При финальном расчёте статистик используется каждое наблюдение, тогда как при оптимизации параметров используются неперекрывающиеся окна со сдвигом $W + 1 = 11$. Такая организация вычис-

лений уменьшает вычислительную стоимость и исключает многократное использование одних и тех же наблюдений в смежных окнах при оценке параметров.

Обработка данных выполнялась отдельно для трёх типов участков GPS-траекторий: `stand`, соответствующих неподвижному состоянию объекта; `move`, соответствующих движению; и `stand_move`, включающих оба состояния. В анализ включались непрерывные участки длиной не менее 100 точек.

1.1.2 Математическая постановка

Для фильтра Калмана рассматривается последовательность наблюдений положения $z_k = \begin{bmatrix} x_k & y_k \end{bmatrix}$. На шаге (k) innovation определяется как разность между фактическим наблюдением и его априорной оценкой: $\nu_k = z_k - H\hat{x}_{k|k-1}$ где H — матрица наблюдения, $(\hat{x}_{k|k-1})$ — прогноз состояния.

Ковариационная матрица innovation имеет вид $S_k = HP_{k|k-1}H^T + R$, где $P_{k|k-1}$ — априорная ковариационная матрица состояния, а (R) — ковариационная матрица ошибки измерения.

Для изотропной модели ошибки измерения использовалось $R = \sigma_{meas}^2 I$.

В CV-модели состояние имеет размерность четыре: $X_k = \begin{bmatrix} x_k & y_k & v_{x,k} & v_{y,k} \end{bmatrix}^T$, а переход между состояниями задаётся матрицей $F_k = \begin{bmatrix} 1 & 0 & \Delta t_k & 0 \\ 0 & 1 & 0 & \Delta t_k \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$.

Матрица шума процесса формируется на основе модели случайного ускорения с параметром σ_{acc} . В RW-модели состояние содержит только координаты, а ковариация процесса определяется параметром σ_{rw} и интервалом времени Δt_k . Реализация обеих моделей непосредственно вычисляет логарифм правдоподобия, квадрат расстояния Махаланобиса и расстояние между наблюдением и оценкой фильтра.

Для двумерной нормально распределённой innovation статистика $M_k^2 = \nu_k^T S_k^{-1} \nu_k$ теоретически имеет распределение $M_k^2 \sim \chi_2^2$. Следовательно, $E[M_k^2] = 2$, а 95-й процентиль равен $\chi_{2;0.95}^2 = 5.991$ Именно эти значения использо-

вались в качестве эталона при проверке калибровки фильтра.

1.1.3 Методика оценки (σ_{meas})

До применения MLE были рассмотрены две прямые оценки дисперсии GPS-измерения на участках stand.

Первая оценка основана на абсолютном разбросе координат:

$$\sigma_x = \text{std}(x - \bar{x}), \quad \sigma_y = \text{std}(y - \bar{y}), \quad \sqrt{\frac{\sigma_x^2 + \sigma_y^2}{2}}.$$

Вторая оценка основана на разностях соседних наблюдений. При предположении независимого одинаково распределённого измерительного шума $\text{Var}(z_i - z_{i-1}) = 2\sigma_{meas}^2$, откуда $\sigma_x = \frac{\text{std}(\Delta x)}{\sqrt{2}}$, $\sigma_y = \frac{\text{std}(\Delta y)}{\sqrt{2}}$, $\sqrt{\frac{\sigma_x^2 + \sigma_y^2}{2}}$.

Обе оценки реализованы непосредственно в процедуре подготовки данных. Полученные результаты существенно различаются между собой. Для 1.csv оценка по абсолютному разбросу составляет 203.80 м, тогда как оценка по соседним разностям составляет 11.21 м. Для 2.csv соответствующие значения равны 1738.45 м и 855.68 м.

Таблица 1.1: Оценки шумов по неподвижным участкам для 1.csv и 2.csv

Файл	Метод	N_{seg}	N_{pts}	σ_{meas} , м	σ_{proc}
1.csv	stand_position_std	79	382003	203.802	–
1.csv	stand_neighbor_diff	79	381924	11.208	–
1.csv	MLE_CV	79	382003	0.5065	$\sigma_{acc} = 0.00744$
1.csv	MLE_RW	79	382003	0.0010	$\sigma_{rw} = 0.3998$
2.csv	stand_position_std	70	50908	1738.453	–
2.csv	stand_neighbor_diff	70	50838	855.683	–
2.csv	MLE_CV	70	50908	0.0133	$\sigma_{acc} = 2.97096$
2.csv	MLE_RW	70	50908	0.0010	$\sigma_{rw} = 54.5432$

Такое различие показывает, что дисперсия координат внутри участков stand не может однозначно интерпретироваться как чистый шум измерения. Абсолютный разброс содержит не только высокочастотную составляющую измерительной ошибки, но и низкочастотные изменения положения. В частности, существенное отличие оценки по абсолютному разбросу от

оценки по соседним разностям является признаком наличия медленного пространственного дрейфа или других нестационарных составляющих.

1.1.4 Оценка параметров методом максимального правдоподобия

Для CV и RW одновременно оптимизировались параметры измерительного шума и шума процесса. Оптимизация проводилась в логарифмическом пространстве параметров с использованием алгоритма L-BFGS-B и трёх различных начальных точек. Для каждого варианта выбирался результат с минимальным значением отрицательного логарифма правдоподобия.

Результаты показали существенную зависимость получаемых параметров от обучающего трека.

Для 1.csv в модели CV были получены:

$$\begin{aligned}\sigma_{meas} &= 0.507 \text{ м}, & \sigma_{acc} &= 0.00744 \text{ м/с}^2 \text{ для stand;} \\ \sigma_{meas} &= 1.864 \text{ м}, & \sigma_{acc} &= 0.01113 \text{ м/с}^2 \text{ для move;} \\ \sigma_{meas} &= 2.753 \text{ м}, & \sigma_{acc} &= 0.00258 \text{ м/с}^2 \text{ для stand_move.}\end{aligned}$$

При обучении на 2.csv параметры CV существенно изменились. Особенно показательным является участок stand: $\sigma_{meas} = 0.0133 \text{ м}$, $\sigma_{acc} = 2.971 \text{ м/с}^2$.

Таким образом, MLE одновременно приводит к практически нулевой ошибке измерения и чрезвычайно высокой интенсивности шума процесса.

Таблица 1.2: Параметры CV, оценённые MLE на 1.csv и 2.csv

Файл	Режим	N_{seg}	N_{pts}	$\sigma_{meas}, \text{ м}$	$\sigma_{acc}, \text{ м/с}^2$	NLL	N_{val}	$\overline{M^2}$	$P_{95}(M)$
1.csv	stand	79	382003	0.5065	0.00744	109284.55	89509	2744.65	90.2
1.csv	move	66	368149	1.8639	0.01113	173214.57	220841	27412.39	7.8
1.csv	stand_move	48	751564	2.7532	0.00258	365719.14	310477	25198.10	10.8
2.csv	stand	70	50908	0.01325	2.97096	59868.34	89509	5.7818	3.1
2.csv	move	75	112371	1.9316	0.03570	61251.05	220841	12606.39	3.7
2.csv	stand_move	76	164323	82.6744	0.02578	178917.55	310477	124.2974	0.02

Для RW наблюдается ещё более выраженная тенденция. На 2.csv оптимизация дала $\sigma_{meas} = 0.001 \text{ м}$ для stand и move, то есть значение достигло

нижней границы, установленной в реализации: $\sigma_{meas}^{min} = 10^{-3}$ м.

Аналогичное поведение наблюдается для 3.csv на участках move и stand_move.

Таблица 1.3: Параметры RW, оценённые MLE

Файл	Режим	N_{seg}	N_{pts}	σ_{meas} , м	σ_{rw}	NLL	N_{val}	$\overline{M^2}$	$P_{95}(M^2)$
1.csv	stand	79	382003	0.0010	0.39977	112731.88	89509	1540.06	55.824
1.csv	move	66	368149	0.0010	6.20449	291948.13	220841	1709.52	5.853
1.csv	stand_move	48	751564	0.00763	4.37285	548657.97	310477	2452.12	11.293
2.csv	stand	70	50908	0.0010	54.54324	60379.18	89509	0.0827	0.003
2.csv	move	75	112371	0.01244	9.29854	97754.49	220841	761.13	2.605
2.csv	stand_move	76	164323	0.01828	10.30279	146163.11	310477	441.73	2.034

Полученная закономерность свидетельствует о вырожденности текущей постановки MLE. Поскольку R определяется через σ_{meas}^2 , а Q — через σ_{acc}^2 или σ_{rw}^2 , изменение двух параметров позволяет частично компенсировать влияние друг друга. Увеличивая шум процесса, модель получает возможность существенно увеличить предсказательную ковариацию $P_{k|k-1}$ и тем самым объяснить крупные ошибки прогнозирования без увеличения R . В предельном случае оптимизации выгодно принять малое σ_{meas} и компенсировать его большим шумом процесса.

Следовательно, факт успешной остановки оптимизатора не является достаточным основанием для признания оценённых параметров физически состоятельными.

1.1.5 Проверка на независимом валидационном треке

Для проверки переносимости параметров использовался независимый трек 3.csv. После калибровки на обучающем наборе итоговые статистики вычислялись на валидационных данных с шагом один, то есть для каждой доступной точки.

Качество калибровки оценивалось сравнением эмпирических значений M^2 с распределением χ^2_2 . Для этого вычислялись среднее значение и 95-й процентиль: $\overline{M^2}$, $P_{95}(M^2)$.

В качестве эталонных значений использовались

$$\overline{M^2}_{theory} = 2, \quad P_{95,theory}(M^2) = 5.991$$

Ни один из рассмотренных вариантов, обученных на 1.csv или 2.csv, не обеспечил приемлемой калибровки на 3.csv. Например, для CV при обучении на 1.csv получены следующие значения:

Таблица 1.4: Параметры M^2 для различных типов участков

Тип участка	$\overline{M^2}$	$P_{95}(M^2)$
stand	2744.65	90.25
move	27412.39	7.86
stand_move	25198.10	10.87

Теоретические значения составляют соответственно 2 и 5.991.

Для параметров, полученных на 2.csv, расхождения имеют иной характер.

Для участка stand CV дал $\overline{M^2} = 5.78$, $P_{95}(M^2) = 3.12$

Для move $\overline{M^2} = 12606.39$, $P_{95}(M^2) = 3.75$

Для stand_move $\overline{M^2} = 124.30$, $P_{95}(M^2) = 0.024$

Таким образом, параметры, полученные на одном треке, не обеспечивают сопоставимого статистического поведения innovation на другом треке.

1.1.6 Анализ распределения статистики Махаланобиса

Полученные значения M^2 показывают, что распределение ошибок существенно отличается от предполагаемого единого распределения χ^2_2 .

Наиболее показательный пример — модель CV, обученная на 2.csv для stand_move:

$$\overline{M^2} = 124.30, \quad P_{95}(M^2) = 0.024.$$

Поскольку 95-й процентиль значительно меньше единицы, основная масса наблюдений имеет чрезвычайно малую нормированную ошибку. Одновременно относительно небольшое число наблюдений формирует значения M^2 , настолько большие, что они существенно увеличивают среднее.

Аналогичное соотношение наблюдается для CV, обученного на 1.csv:

$$\overline{M^2} = 2744.65, \quad P_{95}(M^2) = 90.25$$

для stand, а также

$$\overline{M^2} = 27412.39, \quad P_{95}(M^2) = 7.86$$

для move.

Следовательно, среднее значение M^2 в рассматриваемых экспериментах является недостаточной характеристикой распределения. Наличие редких экстремальных инноваций приводит к существенному расхождению между средним и процентильными характеристиками.

С точки зрения задачи обнаружения аномалий данный результат имеет принципиальное значение. Наблюдаемые данные, по-видимому, содержат две различные статистические составляющие: основную массу наблюдений с относительно малой innovation и редкие крупные отклонения. Поэтому предположение $\nu_k \sim N(0, S_k)$

для всей совокупности GPS-наблюдений не согласуется с экспериментальными результатами.

При этом наличие редких экстремальных значений не обязательно делает фильтр бесполезным для обнаружения аномалий. Напротив, такие значения могут представлять именно тот класс наблюдений, который требуется выделять. В этом случае фильтр Калмана целесообразно рассматривать прежде всего как средство построения базовой модели нормального движения, а статистику M^2 — как показатель отклонения наблюдения от этой модели.

1.1.7 Ограничения текущей постановки

Полученные результаты позволяют выделить несколько ограничений текущего подхода.

Во-первых, отсутствует идентифицируемость параметров R и Q при их одновременной свободной оптимизации. Это приводит к компенсации измерительного и процессного шумов и, как следствие, к физически неправдоподобным значениям σ_{meas} и параметров процесса.

Во-вторых, стационарные участки GPS-треков не являются статисти-

чески однородными. Значительное расхождение между оценкой по абсолютному разбросу и оценкой по разностям соседних точек свидетельствует о наличии дополнительной низкочастотной составляющей. Поэтому непосредственное использование полного пространственного разброса *stand* как оценки ошибки измерения некорректно.

В-третьих, параметры существенно зависят от конкретного GPS-трека. Независимая валидация на 3.csv не подтверждает прямую переносимость параметров, полученных на 1.csv и 2.csv.

В-четвёртых, локальная схема формирования окон принципиально отличается от классического расчёта *likelihood* для одной непрерывной реализации *state-space* модели. Каждое окно начинается с новой инициализации состояния, после чего в процессе MLE используется только *innovation* последнего наблюдения окна. Такая постановка снижает вычислительную стоимость, однако ограничивает непосредственную интерпретацию полученной функции правдоподобия как *likelihood* всего GPS-трека.

1.1.8 Корректировка методики оценки параметров

Для устранения конфаундинга *R* и *Q* целесообразно разделить оценку параметров на два этапа.

На первом этапе должна независимо оцениваться ошибка GPS-измерения. Для этого следует использовать только локально-стационарные фрагменты *stand*, исключив участки с выраженным дрейфом. В качестве исходной оценки может использоваться статистика разностей соседних наблюдений:

$$\sigma_x = \frac{\text{std}(\Delta x)}{\sqrt{2}}, \quad \sigma_y = \frac{\text{std}(\Delta y)}{\sqrt{2}}, \quad \sqrt{\frac{\sigma_x^2 + \sigma_y^2}{2}}.$$

После фиксации (σ_{meas}) на втором этапе необходимо независимо оценивать только параметр шума процесса: σ_{acc} для CV либо σ_{rw} для RW.

Такая постановка уменьшает число свободных параметров MLE и исключает основной канал взаимной компенсации между *R* и *Q*.

Для последующей оценки пригодности модели целесообразно использовать не только среднее и 95-й перцентиль M^2 , но и медиану, 99-й перцентиль, а также доли наблюдений, превышающих заданные пороги: $M^2 >$

5.991, $M^2 > 9.21$, $M^2 > 13.82$.

Эти показатели позволяют одновременно оценивать калибровку основной массы данных и поведение хвоста распределения, непосредственно связанного с обнаружением аномальных GPS-наблюдений.

1.1.9 Промежуточный вывод

В результате проведённого эксперимента реализована вычислительная схема оценки параметров фильтров Калмана CV и RW методом максимального правдоподобия и выполнена их проверка на независимом GPS-треке. Вычислительная реализация позволяет обрабатывать используемые объёмы данных пакетно и выполнять многократные оценки функции правдоподобия. Структура расчёта, включая локальные окна, пакетную обработку и оптимизацию параметров, реализована и формализована.

Вместе с тем полученные параметры не могут на данном этапе рассматриваться как физически достоверные параметры GPS-модели. Основной причиной является совместная оценка измерительного и процессного шумов, приводящая к вырожденным решениям MLE. Наиболее явно этот эффект проявляется для RW, где σ_{meas} систематически достигает нижней границы допустимого диапазона.

Независимая валидация показывает, что параметры, оценённые на отдельных треках, не переносятся на другой трек. Одновременно анализ распределения M^2 выявляет наличие редких экстремальных отклонений на фоне основной массы наблюдений с существенно меньшими ошибками. Это указывает на то, что исходная Gaussian state-space модель не описывает полный спектр наблюдаемых GPS-ошибок.

Таким образом, дальнейшее развитие метода должно быть сосредоточено не на увеличении точности численной оптимизации, а на изменении статистической постановки задачи: независимой оценке σ_{meas} , фиксации этого параметра при последующей калибровке динамической модели и отдельном анализе хвостов распределения innovation для построения критерия обнаружения аномалий.

1.2 Замер 2

1.2.1 Изменение методики калибровки

В предыдущем эксперименте параметры измерительного и процессного шумов оценивались одновременно методом максимального правдоподобия. Полученные результаты выявили взаимную компенсацию параметров R и Q , вследствие которой оценка σ_{meas} в ряде случаев достигала установленной нижней границы.

Для устранения данного эффекта методика калибровки была разделена на два этапа. На первом этапе параметр σ_{meas} оценивается независимо от динамической модели по локально-стационарным фрагментам участков *stand*. После этого полученное значение фиксируется и не участвует в оптимизации MLE. На втором этапе для модели CV оптимизируется только σ_{acc} , а для модели RW — только σ_{rw} .

Участки *stand* предварительно разбиваются на неперекрывающиеся фрагменты длиной 30 точек. При характерном интервале между последовательными измерениями около 10 с такой длине соответствует временной интервал приблизительно 5 мин. Фрагменты длиной менее 20 точек исключаются. Для каждого фрагмента формируется собственная локальная система координат, после чего вычисляются приращения координат и их статистические характеристики.

Для отбора стационарных фрагментов применяются три группы критериев: σ_x, σ_y не должны выходить за установленный диапазон относительно медианных значений по совокупности фрагментов

$$|\overline{\Delta x}| \leq 3 \frac{\sigma_{\Delta x}}{\sqrt{N}}, \quad |\overline{\Delta y}| \leq 3 \frac{\sigma_{\Delta y}}{\sqrt{N}},$$

что ограничивает систематический дрейф локального положения; кроме того, временные интервалы Δt не должны содержать значительных разрывов. В частности, медианный и максимальный интервал внутри фрагмента ограничиваются двукратным медианным значением по совокупности фрагментов.

Такое предварительное выделение локально-стационарных фрагментов

позволяет исключить из оценки σ_{meas} значительную часть низкочастотного дрейфа GPS-положения.

1.2.2 Оценка измерительного шума

Пусть $z_i = s_i + \varepsilon_i$, где s_i — истинное положение, а ε_i — ошибка измерения. Для локально-стационарного участка $s_i \approx s$. Тогда $\varepsilon_i - \varepsilon_{i-1}$.

При предположении независимости последовательных ошибок $\text{Var}(\Delta z) = 2\sigma_{meas}^2$, поэтому оценка стандартного отклонения измерительной ошибки определяется выражением $\sqrt{\frac{\text{Var}(\Delta z)}{2}}$.

Отдельно вычисляются оценки по координатам X и Y : $\sqrt{\frac{\text{Var}(\Delta y)}{2}}$, после чего формируется итоговая изотропная оценка $\sqrt{\frac{\sigma_{meas,x}^2 + \sigma_{meas,y}^2}{2}}$.

Для объединения информации от нескольких локально-стационарных фрагментов используется общая оценка дисперсии, полученная с учётом внутрефрагментных вариаций и числа наблюдений в каждом фрагменте. Перед вычислением дисперсии из приращений каждого фрагмента вычитается его среднее значение. Поэтому локальная составляющая приращений, обусловленная дрейфом или медленным изменением истинной координаты, не включается непосредственно в оценку дисперсии высокочастотной измерительной ошибки.

Полученные оценки представлены в таблице.

Таблица 1.5: Оценённые значения σ_{meas} и число фрагментов

Обучающий трек	$\sigma_{meas,x}$, м	$\sigma_{meas,y}$, м	σ_{meas} , м	Число фрагментов	Принято
1.csv	0.606	0.707	0.658	12 723	7 125
2.csv	1.134	1.295	1.217	1 683	1 106
3.csv	0.576	0.720	0.652	2 981	544

Для 1.csv и 3.csv получены практически одинаковые оценки:

$$\sigma_{meas}^{(1)} = 0.658 \text{ м}, \quad \sigma_{meas}^{(3)} = 0.652 \text{ м}.$$

Относительное различие составляет менее (1%).

В то же время для 2.csv $\sigma_{meas}^{(2)} = 1.217$ м, что приблизительно в 1.85 раза превышает соответствующее значение для 1.csv и 3.csv.

Таким образом, по характеристикам высокочастотной составляющей ошибки измерения треки 1.csv и 3.csv статистически существенно ближе друг к другу, чем 2.csv.

Отношения $\frac{\sigma_{meas,y}}{\sigma_{meas,x}}$ для треков 1.csv, 2.csv и 3.csv составляют соответственно приблизительно 1.17, 1.14 и 1.25. Таким образом, существенной анизотропии ошибки в рассматриваемых данных не выявлено, вследствие чего использование модели $R = \sigma_{meas}^2 I$ остаётся допустимым приближением.

1.2.3 Результаты калибровки модели CV

После фиксации σ_{meas} методом MLE оценивается только параметр σ_{acc} .

В результате для обучающего трека 1.csv получены: $\sigma_{acc} = 0.00626$ м/с² для stand, $\sigma_{acc} = 0.07073$ м/с² для move и $\sigma_{acc} = 0.35922$ м/с² для stand_move.

Для 2.csv соответствующие значения составили
0.09940, 0.04714, 0.07019 м/с².

Для 3.csv, рассматриваемого как дополнительный диагностический эксперимент,

0.4000, 0.4000, 0.0229 м/с².

Таблица 1.6: Оценённые значения σ_{acc} для модели CV

Обучающий трек	σ_{acc} , м/с ² (stand)	σ_{acc} , м/с ² (move)	σ_{acc} , м/с ² (stand_move)
1.csv	0.00626	0.07073	0.35922
2.csv	0.09940	0.04714	0.07019
3.csv	0.40000	0.40000	0.02291

Полученные значения показывают, что интенсивность процессного шума существенно зависит от режима движения.

Особенно это выражено для 1.csv: $\frac{\sigma_{acc,move}}{\sigma_{acc,stand}} \approx 11.3$,

а для stand_move $\frac{\sigma_{acc,standmove}}{\sigma_{acc,stand}} \approx 57.3$.

Следовательно, один и тот же параметр процессного шума не может без

потери статистической адекватности одновременно характеризовать неподвижное и движущееся состояние.

1.2.4 Результаты калибровки модели RW

Для модели RW аналогичная процедура выполнялась при фиксированном σ_{meas} , при этом MLE оптимизировала только σ_{rw} .

Для 1.csv получены:

$\sigma_{rw} = 0.410$ для stand,

$\sigma_{rw} = 6.212$ для move и

$\sigma_{rw} = 4.383$ для stand_move.

Для 2.csv:

$\sigma_{rw} = 9.9995, \quad 9.3136, \quad 9.9994,$

а для 3.csv:

$9.9995, \quad 9.9996, \quad 9.9995$

соответственно.

Таблица 1.7: Оценённые значения σ_{rw} для модели RW

Обучающий трек	σ_{rw} (stand)	σ_{rw} (move)	σ_{rw} (stand_move)
1.csv	0.410	6.212	4.383
2.csv	9.9995	9.3136	9.9994
3.csv	9.9995	9.9996	9.9995

Для нескольких вариантов параметр σ_{rw} практически достигает верхней границы $\sigma_{rw}^{max} = 10$.

В частности, значения 9.9995 и 9.9994 для 2.csv и 3.csv указывают на то, что оптимум MLE находится у границы допустимой области или за её пределами. Следовательно, установленное ограничение снижает возможность определить фактическое положение оптимума. В связи с этим использование $\sigma_{rw} = 10$ как физически обоснованной оценки процесса не может считаться подтверждённым результатом эксперимента. Указанное ограничение необходимо расширить в последующих экспериментах.

1.2.5 Валидация на независимом треке

Параметры, полученные на 1.csv и 2.csv, проверялись на независимом треке 3.csv. В отличие от MLE, при финальном расчёте статистик использовались все локальные окна с шагом один. Для каждой точки рассчитывались: M^2 , медиана, $P_{95}(M^2)$, $P_{99}(M^2)$, а также доли наблюдений, превышающих пороги 5.991, 9.21, 13.82.

Теоретически для двумерной Gaussian-инновации выполняется $M^2 \sim \chi_2^2$, поэтому

$$E[M^2] = 2,$$

$$P_{95}(M^2) = 5.991,$$

$$P_{99}(M^2) = 9.210,$$

$$P_{99.9}(M^2) = 13.816.$$

1.2.6 Валидация модели CV

При обучении на 1.csv для режима move на 3.csv получены:

$$\text{median}(M^2) = 0.234,$$

$$P_{95}(M^2) = 14.175,$$

$$P_{99}(M^2) = 1574.4.$$

Доля превышений порогов составила

$$P(M^2 > 5.991) = 10.49\%,$$

$$P(M^2 > 9.21) = 7.27\%,$$

$$P(M^2 > 13.82) = 5.11\%.$$

Таким образом, центральная часть распределения характеризуется относительно небольшими значениями M^2 , однако верхний хвост существенно тяжелее теоретического распределения χ_2^2 .

Для обучения на 2.csv и последующей проверки на 3.csv для move:

$$\text{median}(M^2) = 0.101,$$

$$P_{95}(M^2) = 6.505,$$

$$P_{99}(M^2) = 588.37.$$

При этом доли превышений равны 5.35%, 3.82%, 2.88%.

Значение P_{95} близко к теоретическому 5.991, однако P_{99} превышает его почти на два порядка. Следовательно, модель CV достаточно точно описывает центральную часть распределения, но не воспроизводит вероятностное поведение редких крупных отклонений. Данная закономерность наблюдается также для `stand_move`, где при приемлемых значениях P_{95} сохраняются значительные значения P_{99} .

Таким образом, для CV характерна следующая структура:

центральная часть $\rightarrow$ приближённо согласуется с моделью,

верхний хвост $\rightarrow$ существенно тяжелее Gaussian.

Это означает, что стандартное требование $M^2 \sim \chi_2^2$ не выполняется для полной выборки, несмотря на удовлетворительное соответствие части распределения.

1.2.7 Валидация модели RW

Для модели RW наиболее близкое к теоретической калибровке значение получено при обучении на 1.csv и валидации на 3.csv в режиме move: $\sigma_{rw} = 6.212$.

Соответствующие характеристики составили

$$\text{median}(M^2) = 2.911,$$

$$P_{95}(M^2) = 5.839,$$

$$P_{99}(M^2) = 7.942,$$

а доли превышений:

$$P(M^2 > 5.991) = 4.10\%,$$

$$P(M^2 > 9.21) = 0.94\%.$$

Эти значения близки к теоретическим 5%, 1%

для соответствующих уровней распределения χ_2^2 . Таким образом, этот эксперимент является наиболее близким к статистически откалиброванной модели среди рассмотренных вариантов.

В то же время при обучении на 2.csv значение

$$\sigma_{rw} = 9.314$$

привело к

$P_{95}(M^2) = 2.598$, $P_{99}(M^2) = 3.532,4$ а доля превышения порога 5.991 составила лишь 0.875%. Следовательно, дисперсия innovation в данном случае завышена: модель формирует слишком широкую предсказательную неопределённость и потому редко интерпретирует наблюдение как статистически значимое отклонение.

Это непосредственно связано с определением статистики

$$M^2 = \nu^T S^{-1} \nu.$$

При увеличении процессного шума увеличивается Q , затем $P_{k|k-1}$, а вслед за ним S_k . Поэтому

$$Q \uparrow \Rightarrow S_k \uparrow \Rightarrow M_k^2 \downarrow.$$

Следовательно, чрезмерно высокий процессный шум снижает чувствительность фильтра к аномальным наблюдениям, поскольку значительная часть отклонений начинает объясняться естественной неопределённостью динамической модели.

1.2.8 Сравнение CV и RW

Эксперимент показывает принципиально различное поведение двух динамических моделей.

Модель CV задаёт более жёсткое ограничение на изменение скорости и потому в большей степени чувствительна к резким изменениям траектории. Это проявляется в значительных значениях P_{99} и долях экстремальных innovation. В частности, для 1.csv $\rightarrow$ 3.csv / move / CV значение

$$P_{99}(M^2) = 1574.4,$$

что свидетельствует о наличии существенно более тяжёлого хвоста, чем допускает χ_2^2 .

Модель RW не содержит явного состояния скорости и допускает значительно более свободное изменение положения. В режиме move это приводит к существенно более близкому соответствию теоретической калибровке. Однако увеличение σ_{rw} сверх необходимого делает модель чрезмерно дисперсионной и снижает величину M^2 .

Таким образом, наблюдается компромисс между гибкостью динамиче-

ской модели и чувствительностью к аномальным наблюдениям:

CV: меньшая гибкость $\Rightarrow$ более выраженные хвосты,

RW: большая гибкость $\Rightarrow$ меньшая чувствительность при завышенном Q .

С точки зрения задачи обнаружения аномалий это означает, что выбор модели не может основываться только на близости распределения M^2 к χ_2^2 . Требуется одновременно учитывать способность модели сохранять различимость между нормальным отклонением и редким крупным выбросом.

1.2.9 Итоговые результаты эксперимента

Новая схема калибровки устранила ранее наблюдавшееся вырождение оценки σ_{meas} : параметр больше не оптимизируется совместно с процессным шумом и принимает согласованные значения порядка 0.65 м

для 1.csv и 3.csv. Таким образом, независимая оценка измерительного шума позволила перейти от искусственно вырожденных решений к параметрам, обладающим статистической воспроизводимостью между близкими треками.

Одновременно эксперимент показал, что трек 2.csv имеет существенно отличающуюся характеристику измерительного шума:

$$\sigma_{meas} = 1.217 \text{ м},$$

что указывает на наличие отличающихся условий регистрации или статистических свойств исходных данных.

Для динамической части наиболее благоприятный результат получен для модели RW в режиме move при обучении на 1.csv и валидации на 3.csv:

$$P_{95}(M^2) = 5.839,$$

$$P_{99}(M^2) = 7.942,$$

$$P(M^2 > 5.991) = 4.10\%.$$

Эти характеристики близки к теоретическим значениям распределения χ_2^2 .

В то же время для ряда экспериментов RW достигает верхней границы $\sigma_{rw} = 10$, что свидетельствует о необходимости расширения диапа-

зона оптимизации. Дополнительного исследования требует также низкая доля локально-стационарных фрагментов в 3.csv: принято только 544 из 2981 фрагментов, то есть около 18.2%. Это может указывать либо на существенно менее стационарные условия регистрации, либо на чрезмерную строгость критериев отбора.

Объединённый класс `stand_move` не следует использовать как однородный набор для оценки единственного параметра процессного шума. Его более корректно представлять как последовательность режимов с отдельной калибровкой.

Таким образом, проведённый этап подтвердил принципиальную работоспособность независимой оценки σ_{meas} и выявил режимную зависимость динамики GPS-траектории. Основным результатом является переход от единой динамической модели к гипотезе о необходимости режимно-зависимой фильтрации. Дальнейшее исследование должно быть направлено на проверку устойчивости этой схемы и её непосредственной эффективности при обнаружении аномальных наблюдений.

1.3 Замер 3

1.3.1 Постановка дополнительного эксперимента

На следующем этапе была исследована устойчивость получаемых параметров фильтра Калмана и уточнены критерии оценки качества калибровки. Основное изменение заключалось в том, что оценка σ_{meas} выполнялась для трёх размеров локального стационарного фрагмента:

$$L \in 20, 30, 60.$$

Итоговое значение σ_{meas} определялось как медиана трёх полученных оценок. Одновременно для оценки устойчивости рассчитывались коэффициент вариации $\frac{s_\sigma}{\bar{\sigma}}$,

где s_σ — выборочное стандартное отклонение трёх оценок, а $\bar{\sigma}$ — их среднее значение, и отношение $\frac{\max(\sigma_{meas})}{\min(\sigma_{meas})}$.

Таким образом, устойчивость оценивалась одновременно по абсолютно-

му диапазону и относительной изменчивости результата. Реализация эксперимента непосредственно предусматривает расчёт σ_{meas} при длинах фрагмента 20, 30 и 60 точек и формирование итоговой оценки по медиане. Дополнительно верхняя граница параметра RW была увеличена с

$$\sigma_{rw}^{max} = 10$$

до

$$\sigma_{rw}^{max} = 100.$$

Это изменение позволило проверить, являлось ли ранее наблюдавшееся значение $\sigma_{rw} \approx 10$ следствием ограничения оптимизации либо действительным положением минимума функции правдоподобия.

Для оценки validation теперь отдельно анализировались характеристики центральной части распределения M^2 и его хвоста. Центральная калибровка определялась по P_{95} и P_{99} , а хвостовая — по долям превышений теоретических порогов χ_2^2 .

1.3.2 Устойчивость оценки измерительного шума

Для 1.csv получены следующие оценки:

$$\sigma_{meas}(20) = 0.6197 \text{ м},$$

$$\sigma_{meas}(30) = 0.6584 \text{ м},$$

$$\sigma_{meas}(60) = 0.7148 \text{ м}.$$

Итоговая оценка, являющаяся медианой, составила

$$\sigma_{meas} = 0.6584 \text{ м}.$$

При этом

$$CV_{\sigma} = 7.20\%,$$

а

$$R_{\sigma} = 1.154.$$

Изменение длины фрагмента в три раза приводит, таким образом, лишь к умеренному изменению оценки измерительного шума.

Таблица 1.8: Зависимость σ_{meas} от длины локального стационарного фрагмента

Обучающий трек	$\sigma_{meas}(20)$, м	$\sigma_{meas}(30)$, м	$\sigma_{meas}(60)$, м	CV_σ ,	R_σ
1.csv	0.6197	0.6584	0.7148	7.20	1.154
2.csv	1.1033	1.2215	1.3568	10.33	1.230
3.csv	0.3356	0.6566	0.9633	48.15	2.870

Для 2.csv получены:

$$\sigma_{meas}(20) = 1.1033 \text{ м},$$

$$\sigma_{meas}(30) = 1.2215 \text{ м},$$

$$\sigma_{meas}(60) = 1.3568 \text{ м}.$$

Медианная оценка:

$$\boxed{\sigma_{meas} = 1.2215 \text{ м}},$$

при

$$CV_\sigma = 10.33\%$$

и

$$R_\sigma = 1.230$$

Следовательно, оценка для 2.csv также сохраняет удовлетворительную устойчивость относительно изменения масштаба окна, однако её изменчивость приблизительно в 1.4 раза выше, чем для 1.csv.

Наиболее существенное изменение наблюдается для 3.csv:

$$\sigma_{meas}(20) = 0.3356 \text{ м},$$

$$\sigma_{meas}(30) = 0.6566 \text{ м},$$

$$\sigma_{meas}(60) = 0.9633 \text{ м}.$$

При этом

$$\sigma_{meas} = 0.6566 \text{ м},$$

$$CV_\sigma = 48.15\%,$$

$$R_\sigma = 2.870.$$

Таким образом, несмотря на близость медианной оценки 3.csv к оценке 1.csv, сама оценка для 3.csv не является устойчивой относительно масштаба локального фрагмента.

Характер зависимости имеет монотонный вид:

$$0.3356 \rightarrow 0.6566 \rightarrow 0.9633$$

при увеличении длины фрагмента от 20 до 60 точек. Это означает, что при увеличении временного масштаба в стационарных участках начинает проявляться дополнительная низкочастотная составляющая вариации координат. В коротких окнах преобладает локальная составляющая измерительного шума, тогда как на более продолжительных интервалах в оценку начинает включаться дрейф.

Полученный результат имеет важное методическое значение. Для 1.csv и 2.csv оценка σ_{meas} сохраняет устойчивость в широком диапазоне используемых масштабов, тогда как 3.csv демонстрирует существенную зависимость от длины фрагмента. Следовательно, сама по себе медианная оценка

$$\text{median}(\sigma_{meas}(20), \sigma_{meas}(30), \sigma_{meas}(60))$$

не является достаточным критерием устойчивости.

Для 3.csv значение

$$\sigma_{meas} = 0.6566 \text{ м}$$

численно близко к 1.csv, но диапазон

$$0.3356 \dots 0.9633 \text{ м}$$

указывает на существенно меньшую временную стационарность исходных данных. Следовательно, близость итоговых медианных значений не должна интерпретироваться как полное совпадение статистических характеристик треков.

1.3.3 Выбор масштаба локального фрагмента

Сопоставление результатов для 1.csv и 3.csv позволяет отдельно оценить выбор длины фрагмента ($L=30$).

Для 1.csv:

$$0.620, \quad 0.658, \quad 0.715 \text{ м},$$

а для 3.csv:

$$0.336, \quad 0.657, \quad 0.963 \text{ м}.$$

В обоих случаях значение, соответствующее ($L=30$), практически совпадает:

$$\sigma_{meas}^{(1)}(30) = 0.6584 \text{ м},$$

$$\sigma_{meas}^{(3)}(30) = 0.6566 \text{ м}.$$

Относительное расхождение составляет около (0.3%).

Таким образом, масштаб

$$\boxed{L = 30}$$

обеспечивает наилучшее согласование оценки между обучающим и валидационным треками из рассматриваемых вариантов. При интервале дискретизации порядка 10 с это соответствует приблизительно 5 мин наблюдений.

При этом значения ($L=20$) и ($L=60$) целесообразно сохранять как диагностические режимы, позволяющие выявлять зависимость оценки от временного масштаба.

1.3.4 Результаты калибровки CV

После фиксации σ_{meas} параметры модели CV практически не изменились относительно предыдущего эксперимента.

Для связки 1.csv $\rightarrow$ 3.csv в режиме move:

$$\sigma_{acc} = 0.07072 \text{ м/с}^2.$$

При валидации получены:

$$\text{median}(M^2) = 0.2343,$$

$$P_{95}(M^2) = 14.171,$$

$$P_{99}(M^2) = 1573.2.$$

Доли превышения порогов:

$$P(M^2 > 5.991) = 10.49\%,$$

$$P(M^2 > 9.21) = 7.27\%,$$

$$P(M^2 > 13.82) = 5.11\%.$$

Теоретические значения для распределения χ_2^2 равны соответственно 5%, 1% и 0.1%. Следовательно, основная часть распределения и его верхний хвост характеризуются существенно различным поведением.

Для 2.csv $\rightarrow$ 3.csv / move / CV:

$$\sigma_{acc} = 0.04704 \text{ м/с}^2,$$

$$P_{95}(M^2) = 6.475,$$

$$P_{99}(M^2) = 581.845.$$

Доля превышения 5.991 составляет 5.33%, то есть непосредственно около теоретического уровня 5%, однако для более высоких порогов наблюдается значительное превышение теории.

Таким образом, для CV характерно наличие относительно корректно воспроизводимой центральной области распределения и существенно более тяжёлого верхнего хвоста. Величина P_{99} является наиболее показательным индикатором этого эффекта.

1.3.5 Результаты калибровки RW после снятия ограничения $\sigma_{rw} \leq 10$

Расширение диапазона оптимизации до

$$0 < \sigma_{rw} \leq 100$$

не привело к существенному изменению оптимальных значений для режимов, в которых ранее наблюдалась область около 10.

Например, для 2.csv получено:

$$\sigma_{rw} = 9.9995$$

для stand,

$$\sigma_{rw} = 9.3137$$

для move,

$$\sigma_{rw} = 9.9994$$

для stand_move.

Аналогичная картина наблюдается для 3.csv:

$$\sigma_{rw} \approx 10$$

для всех трёх типов сегментов.

Поскольку новая верхняя граница равна 100, а оптимум по-прежнему располагается около 10, прежний результат не был вызван ограничением

$$\sigma_{rw}^{max} = 10.$$

Следовательно, значения порядка

$$\boxed{\sigma_{rw} \approx 10}$$

представляют собой внутреннюю область оптимума для данных режимов, а не результат принудительного ограничения параметра. Это существенно уточняет интерпретацию предыдущего эксперимента.

Одновременно для $1.csv \rightarrow 3.csv$ / *move* сохраняется

$$\sigma_{rw} = 6.212,$$

что подтверждает устойчивость этого результата и его отличие от значений около 10, характерных для других режимов и обучающих выборок.

1.3.6 Валидация RW в режиме движения

Наиболее согласованный результат по-прежнему получен для

$1.csv \rightarrow 3.csv$, *move*, *RW*. Параметр процесса:

$$\sigma_{rw} = 6.212.$$

Характеристики распределения:

$$\text{median}(M^2) = 2.911,$$

$$P_{95}(M^2) = 5.839,$$

$$P_{99}(M^2) = 7.942.$$

Доли превышения порогов:

$$P(M^2 > 5.991) = 4.10\%,$$

$$P(M^2 > 9.21) = 0.94\%,$$

$$P(M^2 > 13.82) = 0.873\%.$$

Первые два значения практически совпадают с теоретическими: 5%è1%.

Значение P_{95} также практически совпадает с 5.991.

Таким образом, центральная часть распределения RW в этом эксперименте хорошо согласуется с Gaussian-моделью.

Вместе с тем вероятность превышения уровня 13.82 равна 0.873%, что приблизительно в $\frac{0.873}{0.1} = 8.73$

раз превышает теоретическое значение. Это указывает на сохранение тяжёлого хвоста даже в наиболее удачном варианте модели.

Следовательно, полученные данные поддерживают представление об innovation как о смеси основной Gaussian-составляющей и редких крупных ошибок:

$$p(\nu) \approx (1 - \varepsilon)N(0, S) + \varepsilon f_{heavy}(\nu),$$

где f_{heavy} описывает редкие выбросы, не объясняемые основной Gaussian-моделью.

1.3.7 Режимная зависимость процессного шума

Результаты подтверждают существенную зависимость динамической модели от режима движения.

Для 1.csv:

$$\sigma_{acc,stand} = 0.00626,$$

$$\sigma_{acc,move} = 0.07072,$$

$$\sigma_{acc,stand_{move}} = 0.35921.$$

Для RW:

$$\sigma_{rw,stand} = 0.410,$$

$$\sigma_{rw,move} = 6.212,$$

$$\sigma_{rw,stand_{move}} = 4.383.$$

Например,

$$\frac{\sigma_{rw,move}}{\sigma_{rw,stand}} \approx 15.2.$$

Следовательно, stand и move представляют собой статистически различные динамические режимы и не должны описываться одним параметром процессного шума.

Дополнительное подтверждение даёт класс stand_move. Для него используется единый параметр процесса, хотя данные содержат одновременно неподвижные и движущиеся фрагменты. В результате модель вынуждена выбирать компромисс между различными динамическими режимами. Именно поэтому stand_move целесообразно рассматривать не как самостоятельный однородный класс, а как последовательность переходов

STATIONARY $\leftrightarrow$ MOVING.

1.3.8 Выбор рабочей конфигурации

Полученные результаты позволяют сформировать рабочую конфигурацию для следующего этапа исследования.

Для связки 1.csv $\rightarrow$ 3.csv, демонстрирующей наиболее близкие статистические свойства, целесообразно зафиксировать

$$\sigma_{meas} = 0.6584 \text{ м}.$$

Данная оценка одновременно соответствует центральному значению зависимости по длине фрагмента для 1.csv и практически совпадает с оценкой 3.csv при (L=30):

$$\sigma_{meas}^{(1)}(30) = 0.6584 \text{ м},$$

$$\sigma_{meas}^{(3)}(30) = 0.6566 \text{ м}.$$

Для режима stand в качестве исходной динамической модели целесообразно рассматривать CV с

$$\sigma_{acc} = 0.00626 \text{ м/с}^2,$$

а для режима move — RW с

$$\sigma_{rw} = 6.212.$$

Модель CV для move с

$$\sigma_{acc} = 0.07072 \text{ м/с}^2$$

следует сохранить как альтернативную модель и источник дополнительного признака, поскольку она формирует существенно более выраженный хвост M^2 . Это предоставляет возможность в дальнейшем сравнить не только абсолютное качество калибровки, но и полезность различных моделей непосредственно для обнаружения аномалий.

1.3.9 Выводы по этапу

Проведённый эксперимент подтвердил устойчивость оценки измерительного шума для 1.csv и 2.csv при изменении длины локального стационарного фрагмента. Для 1.csv коэффициент вариации трёх оценок составил 7.20%, для 2.csv — 10.33%. Для 3.csv коэффициент вариации составил 48.15%, что указывает на существенно большую зависимость оценки от временного масштаба и наличие низкочастотной составляющей в стационарных участках.

Наиболее согласованной длиной стационарного фрагмента является 30 точек: при этом значения σ_{meas} для 1.csv и 3.csv практически совпадают.

Длины 20 и 60 точек целесообразно использовать в дальнейшем как диагностические, а не как основные.

Расширение диапазона σ_{rw} до 100 показало, что значения около 10 для ряда режимов не являются артефактом верхней границы предыдущего эксперимента. Это позволяет рассматривать их как собственно результат оптимизации.

Наиболее близкое к теоретической Gaussian-калибровке распределение innovation получено для

$$\boxed{1.csv \rightarrow 3.csv, \quad move, \quad RW}$$

при

$$\sigma_{meas} = 0.6584 \text{ м}, \quad \sigma_{rw} = 6.212.$$

Для этого варианта

$$P_{95}(M^2) = 5.839,$$

$$P_{99}(M^2) = 7.942,$$

$$P(M^2 > 5.991) = 4.10\%,$$

$$P(M^2 > 9.21) = 0.94\%.$$

При этом уровень $M^2 > 13.82$ наблюдается значительно чаще теоретического значения, что указывает на сохранение тяжёлого хвоста.

Таким образом, дальнейшая работа должна быть перенесена с калибровки параметров на непосредственно задачу классификации GPS-наблюдений. Фильтр Калмана уже позволяет сформировать набор информативных признаков, отражающих как абсолютное отклонение от прогноза, так и его нормированную статистическую значимость.

В качестве следующего этапа целесообразно перейти к непосредственному формированию признаков классификации аномалий:

$$M_{CV}^2, \quad M_{RW}^2,$$

$$\log L_{CV}, \quad \log L_{RW},$$

$$d_{CV}, \quad d_{RW},$$

где d — геометрическое расстояние между наблюдаемым положением и оценкой фильтра, и исследовать их разделяющую способность относительно размеченных состояний normal/anomaly.

Глава 2

Классификация

2.1 Опыт 1

2.1.1 Постановка задачи

На следующем этапе исследовалась не только статистическая калибровка фильтров Калмана, но и непосредственная способность получаемых от фильтра статистик разделять нормальные и аномальные точки GPS-трека.

В качестве исходных признаков рассматривались статистики, формируемые фильтрами постоянной скорости (CV) и случайного блуждания (RW):

$$\begin{aligned} M_{CV}^2, & \quad M_{RW}^2, \\ d_{CV}, & \quad d_{RW}, \\ \log L_{CV}, & \quad \log L_{RW}, \end{aligned}$$

где M^2 — квадрат расстояния Махаланобиса инновации, d — расстояние между наблюдаемой и прогнозируемой позициями, $\log L$ — логарифм предсказательной плотности наблюдения.

Также исследовалось совместное использование статистик CV и RW. В качестве базового классификатора применялась логистическая регрессия; дополнительно анализировались деревья решений.

Основной целью являлось определение того, какие статистики содержат наибольшую информацию об аномальности точки, а также установление различий между задачами бинарного обнаружения anomaly и трёхклассового разделения stand / move / anomaly

2.1.2 Экстремальный дисбаланс классов

Наиболее существенным свойством выборки оказался экстремальный дисбаланс между нормальными и аномальными точками.

Доля аномалий в validation оценивается приблизительно как

$$P(anomaly) \approx 1.45 \cdot 10^{-4},$$

то есть около 0.0145% точек, или примерно одна аномальная точка на (6900) наблюдений.

Это обстоятельство существенно влияет на интерпретацию стандартных метрик классификации. В частности, даже относительно небольшая доля ложных срабатываний приводит к большому числу false positive по отношению к числу истинных аномалий.

Поэтому в дальнейшей оценке основное внимание уделялось следующим характеристикам:

ROC-AUC,

PR-AUC,

Recall,

FPR,

а также числу ложных обнаружений на одну истинную аномалию.

Метрики ассигасу и F1 при таком соотношении классов не могут рассматриваться как достаточные характеристики качества детектора.

2.1.3 Бинарное обнаружение аномальных точек

Для задачи normal / anomaly наиболее сильные результаты получены для фильтра постоянной скорости CV.

Для профиля from_1:

$$ROC-AUC(\log L_{CV}) = 0.9054,$$

$$PR-AUC(\log L_{CV}) = 0.01113.$$

Для квадрата расстояния Махаланобиса:

$$ROC-AUC(M_{CV}^2) = 0.8591,$$

$$PR-AUC(M_{CV}^2) = 0.01073.$$

Для геометрического расстояния:

$$ROC-AUC(d_{CV}) = 0.8234,$$

$$PR-AUC(d_{CV}) = 0.00813.$$

Таким образом, для CV наблюдается иерархия информативности

$$\log L_{CV}$$

$$M_{CV}^2$$

$$d_{CV}.$$

Полученный результат имеет непосредственное математическое объяснение. Предсказательная логарифмическая вероятность наблюдения имеет вид $-\frac{1}{2} [d \log(2\pi) + \log \det S_k + M_k^2]$.

Следовательно, $\log L$ учитывает не только величину инновации, но и её ковариацию S_k . Поэтому он потенциально содержит больше информации, чем одно значение M^2 .

2.1.4 Сравнение CV и RW при бинарном обнаружении anomaly

Преимущество CV сохраняется на различных обучающих профилях.

Для from_1:

$$ROC-AUC_{CV} = 0.8009,$$

$$ROC-AUC_{RW} = 0.5967.$$

Для from_2:

$$ROC-AUC_{CV} = 0.7676,$$

$$ROC-AUC_{RW} = 0.5920.$$

Таким образом,

$$CV \gg RW$$

по способности ранжировать аномальные точки.

Наиболее существенная разница наблюдается для логарифма правдоподобия: 0.9054 против 0.6210 для from_1, а для from_2 соответственно 0.8639 и 0.5776.

Следовательно, в исследуемых данных модель постоянной скорости существенно лучше согласуется со структурой отклонений аномальных точек.

Полученный результат следует трактовать не как абсолютное превосходство CV над RW, а как различие областей информативности моделей: CV оказывается более чувствительной к нарушению ожидаемой динамики движения.

2.1.5 Информативность совместных признаков CV+RW

Исследование совместного использования признаков выявило результат, который не проявляется при анализе только ROC-AUC.

Для from_1:

$$ROC-AUC_{CV} = 0.8009,$$

$$ROC-AUC_{CV+RW} = 0.8132.$$

При этом

$$PR-AUC_{CV} = 0.00812,$$

а

$$PR-AUC_{CV+RW} = 0.03042.$$

Таким образом,

$$\frac{0.03042}{0.00812} \approx 3.75.$$

Для from_2 аналогичное отношение составляет

$$\frac{0.03132}{0.00731} \approx 4.28.$$

Следовательно, совместное использование CV и RW существенно увеличивает precision-recall сигнал для редкого положительного класса, несмотря на отсутствие сопоставимого выигрыша по ROC-AUC.

Это означает, что RW содержит дополнительную информацию, не полностью дублирующую CV. Однако текущая линейная модель не всегда способна эффективно преобразовать эту информацию в итоговое решение с заданным порогом.

Полученный результат является основанием для дальнейшего исследования нелинейного объединения признаков.

2.1.6 Ограничения пороговой классификации

Для $from_1$ / CV при стандартном пороге логистической регрессии получено:

$$ROC-AUC = 0.8009,$$

$$Recall = 0.7556,$$

$$Precision = 0.000479.$$

Такое сочетание метрик не является противоречивым. При

$$P(anomaly) \approx 1.45 \cdot 10^{-4}$$

даже относительно небольшой FPR приводит к значительному числу false positive.

Даже непосредственный подбор порога по CV $\log_likelihood$ не устраняет эту проблему. Для $from_1$ при $threshold = -8.1366$ получено:

$$Recall = 0.8222,$$

$$Precision = 0.001509,$$

$$F1 = 0.003012.$$

Таким образом, увеличение F1 относительно стандартного порога не приводит к пригодной precision.

Следовательно, правило

$$\log L < threshold$$

не может на данном этапе непосредственно использоваться как рабочий production-detector.

Логистическую регрессию в текущем эксперименте целесообразно рассматривать прежде всего как средство проверки информационной ценности признаков.

2.1.7 Влияние профиля калибровки

Для CV качество обнаружения anomaly оказалось выше при использовании профиля $from_1$, чем $from_2$.

Для CV $\log_likelihood$:

$$ROC-AUC_{from_1} = 0.9054,$$

$$ROC-AUC_{from_2} = 0.8639.$$

Для M^2 :

$$ROC-AUC_{from_1} = 0.8591,$$

$$ROC-AUC_{from_2} = 0.8039.$$

При этом ранее для этих профилей были получены различные оценки измерительного шума:

$$\sigma_{meas}^{(1)} = 0.6584 \text{ м},$$

$$\sigma_{meas}^{(2)} = 1.2215 \text{ м}.$$

Таким образом, увеличение оценки measurement noise приводит к расширению допустимой неопределённости фильтра и снижает чувствительность к относительно небольшим отклонениям.

При этом совпадение $\sigma_{meas}^{(1)} \approx \sigma_{meas}^{(3)}$

само по себе не гарантирует совпадения динамических параметров моделей. Для from_3 были получены существенно отличающиеся значения:

$$\sigma_{acc} \approx 4.095,$$

$$\sigma_{rw} \approx 100.985,$$

тогда как для from_1:

$$\sigma_{acc} \approx 0.07072,$$

$$\sigma_{rw} \approx 6.212.$$

Это подтверждает сделанный на предыдущем этапе вывод о необходимости раздельного анализа measurement noise и process noise.

2.1.8 Трёхклассовое разделение stand / move / anomaly

При переходе от бинарного обнаружения anomaly к трёхклассовой классификации структура результатов существенно изменяется.

Наиболее сильным становится фильтр RW.

Для from_1 / RW / filter_distance:

$$Balanced Accuracy = 0.6755,$$

$$Macro F1 = 0.53465,$$

при этом

$$F1_{stand} = 0.74325,$$

$$F1_{move} = 0.85582,$$

$$F1_{anomaly} = 0.004878.$$

Для from_3 / RW / Mahalanobis:

$$Balanced Accuracy = 0.6393,$$

$$Macro F1 = 0.5370,$$

$$F1_{stand} = 0.7396,$$

$$F1_{move} = 0.8687,$$

$$F1_{anomaly} = 0.002697.$$

Таким образом, RW хорошо разделяет *stand* $\leftrightarrow$ *move*, однако практически не отделяет *anomaly* от нормальных режимов.

Это позволяет интерпретировать RW не столько как detector аномалий, сколько как статистический индикатор динамического режима трека.

2.1.9 Различие специализации CV и RW

Совместное рассмотрение бинарной и трёхклассовой задач позволяет сформулировать следующую рабочую интерпретацию:

RW $\rightarrow$ идентификация режима движения,

CV $\rightarrow$ выявление нарушения ожидаемой динамики.

Для RW получены высокие значения F1 для классов *stand* и *move*, достигающие примерно 0.73-0.87, при крайне низком F1 для *anomaly*.

Для CV наблюдается обратная картина: его статистики значительно лучше ранжируют аномальные точки в бинарной постановке, однако хуже разделяют физические режимы *stand* и *move*.

Таким образом, результат эксперимента не сводится к утверждению, что один из фильтров лучше другого. Полученные статистики отражают различные свойства временного ряда.

2.1.10 Проверка трёхклассовой логистической регрессией

Для from_1 / RW логистическая регрессия дала:

$$Macro F1 = 0.5167,$$

$$Balanced Accuracy = 0.6643,$$

$$\begin{aligned}
F1_{stand} &= 0.7484, \\
F1_{move} &= 0.8002, \\
F1_{anomaly} &= 0.001424. \\
\text{Для from_1 / CV:} \\
Macro\ F1 &= 0.2834, \\
F1_{stand} &= 0.4746, \\
F1_{move} &= 0.3744, \\
F1_{anomaly} &= 0.00103.
\end{aligned}$$

Тем самым результаты одиночных статистик подтверждаются и в многоклассовой линейной модели: RW оказывается значительно более информативным для идентификации режима движения.

Совместное добавление CV к RW, однако, почти не изменяет макро-F1. Для from_2:

$$\begin{aligned}
MacroF1_{RW} &= 0.505704, \\
MacroF1_{CV+RW} &= 0.505746.
\end{aligned}$$

Для from_3 прирост составляет лишь $0.498856 \rightarrow 0.502029$.

Следовательно, в трёхклассовой линейной классификации основной объём информации о stand / move извлекается из RW-признаков.

2.1.11 Роль преобразований признаков

Отдельно исследовались монотонные преобразования исходных статистик:

$$\sqrt{M^2}$$

и

$$\log(1 + d).$$

Поскольку

$$\sqrt{M^2}$$

является монотонным преобразованием M^2 , а

$$\log(1 + d)$$

— монотонным преобразованием d , для threshold- и rank-based метрик они не создают нового порядка объектов.

Это соответствует наблюдаемому практически совпадающему качеству признаков `mahalanobis` и `sqrt_mahalanobis`, а также `filter_distance` и `log1p_filter_distance`.

Следовательно, в дальнейших экспериментах нет необходимости рассматривать данные преобразования как независимые источники информации. Их использование оправдано прежде всего при применении моделей, чувствительных к масштабу или форме распределения признаков.

2.1.12 Интерпретация PR-AUC при экстремальном дисбалансе

При

$$P(anomaly) \approx 1.45 \cdot 10^{-4}$$

baseline для PR-AUC случайного классификатора находится приблизительно на том же уровне:

$$PR_{baseline} \approx 0.000145.$$

Для совместного набора CV+RW на `from_2` получено:

$$PR-AUC = 0.031324.$$

Более корректная формулировка результата состоит в том, что модели уже формируют существенно более информативное ранжирование аномальных точек по сравнению со случайным классификатором, однако достигнутый уровень false positive пока не позволяет непосредственно использовать полученный результат в качестве итогового решения.

2.1.13 Сводный анализ параметров моделей

Полученные профили параметров можно представить следующим образом:

Таблица 2.1: Оценённые параметры профилей

Профиль	$\sigma_{meas}, \text{ м}$	CV σ_{acc}	RW σ_{rw}
from_1	0.6584	0.07072	6.212
from_2	1.2215	0.04704	9.314
from_3	0.6566	4.095	100.985

Особенно существенно, что

$$\sigma_{meas}^{(1)} \approx \sigma_{meas}^{(3)},$$

но одновременно

$$\sigma_{acc}^{(1)} \ll \sigma_{acc}^{(3)},$$

и

$$\sigma_{rw}^{(1)} \ll \sigma_{rw}^{(3)}.$$

Следовательно, измерительный шум и динамический шум являются различными характеристиками данных и не могут быть объединены в единый параметр неопределённости.

2.1.14 Методологическое ограничение оценки порога

В текущей постановке оптимальный `threshold` подбирается на объединённой обучающей выборке `1.csv + 2.csv`, после чего оценивается на `3.csv`. Такой подход корректен для независимой `validation`, однако `train`-метрики уже не являются независимой оценкой качества, поскольку `threshold` адаптируется на тех же данных.

Поэтому значения `train_F1` и `train_BalancedAccuracy` не следует использовать как доказательство обобщающей способности модели.

Для следующего этапа целесообразно использовать схему `leave-one-track-out` или `grouped cross-validation`, например:

$$1.csv \rightarrow 2.csv,$$

$$2.csv \rightarrow 1.csv.$$

Это позволит оценивать устойчивость самого правила обнаружения, а не только его соответствие конкретной смеси обучающих треков.

2.1.15 Критерий дальнейшей оптимизации

Для эксплуатационного детектора максимизация F1 не является достаточной целью. При $P(anomaly) \approx 1.45 \cdot 10^{-4}$ даже $FPR = 0.01$ означает примерно $\frac{0.01}{0.000145} \approx 69$ ложных положительных решений на одну истинную аномалию в среднем.

Такой способ оценки непосредственно соответствует практической задаче: определить, какую долю аномалий удаётся обнаружить при заранее ограниченном количестве ложных срабатываний.

2.1.16 Итоговые результаты этапа

На основании проведённых экспериментов сформированы следующие выводы.

Для бинарного обнаружения `normal` / `anomaly` наиболее информативной моделью является CV. Максимальный полученный показатель составил

$$ROC-AUC \approx 0.9054$$

для CV `log_likelihood`.

RW существенно лучше подходит для идентификации физических режимов `stand` / `move`. Для его статистик получены значения

$$F1_{stand} \approx 0.73 - 0.83,$$

$$F1_{move} \approx 0.85 - 0.87.$$

Монотонные преобразования $M^2 \rightarrow \sqrt{M^2}$ и $d \rightarrow \log(1 + d)$ не добавляют новой ранговой информации и потому не должны рассматриваться как независимые признаки.

$RW \rightarrow$ определение режима движения
--

$CV \rightarrow$ обнаружение нарушения ожидаемого движения
--

$CV + RW \rightarrow$ совместный detector редких аномалий

Однако последнее утверждение пока является рабочей гипотезой: наличие дополнительной информации в объединённых признаках подтверждено ростом PR-AUC, но эффективный механизм их объединения и рабочий порог детекции ещё не определены.